

O corpus do projeto: *o Porto de Santos — o lugar, a autoridade pública e o fundador*

Equipe Shannon

Santos-SP, 2 de outubro de 2026

Fatec Baixada Santista, Rubens Lara | Tecnologia em Ciência de Dados
Projeto Integrador III — Motor de Busca | Prof. Dr. João Paulo Ferreira de Mello
Adriane da Costa Santos (RA 0051352511040) Danilo Prado de Lima Silva (RA 0051352521019)
Victória Cabral Quintério (RA 0051352521033)
Repositório: `projetointegrador3`

1 Introdução

O motor de busca do grupo é sobre o Porto de Santos, o porto mais movimentado da América Latina e o eixo econômico da Baixada Santista. Quem o usaria é um estudante, jornalista ou analista regional que precisa achar *a frase* que responde a uma dúvida sobre o porto, e não um artigo inteiro para ler. Em recuperação de informação, o que se atende é a *necessidade de informação* de alguém, não a consulta literal (MANNING; RAGHAVAN; SCHÜTZE, 2008, cap. 1); por isso as perguntas vieram antes do corpus: **(1)** onde fica o Porto de Santos; **(2)** quem administra o porto hoje; **(3)** quem foi Francisco de Paula Ribeiro e qual a sua ligação com o porto. Este texto apresenta a fonte, descreve como o corpus foi montado e mostra, com números, que ele responde às três perguntas.

2 A fonte e o documento

O texto vem da Wikipédia em português, sob licença CC BY-SA, de três páginas: *Porto de Santos* (WIKIPÉDIA, 2026c), *Autoridade Portuária de Santos* (WIKIPÉDIA, 2026a) e *Francisco de Paula Ribeiro* (WIKIPÉDIA, 2026b), salvas em agosto de 2026. Cada página cobre um eixo de uma pergunta: o **lugar** (pergunta 1), a **autoridade pública** que administra o porto (pergunta 2) e o **fundador** histórico (pergunta 3). O corpus tem $N = 122$ documentos vindos de 3 páginas.

Um documento é **uma frase pontuada**, identificada como $dN.k$ (página N , frase k). O critério foi “a menor unidade que responde sozinha a uma pergunta”: o artigo inteiro faria a busca devolver “a resposta está no artigo do porto” sem dizer onde, e o parágrafo — padrão do curso — daria só 18 documentos, abaixo da faixa pedida e misturando assuntos. A frase $d1.1$, “Porto de Santos é um porto estuarino, localizado nos municípios de Santos, Guarujá e...”, responde sozinha à pergunta 1.

A motivação foi o conhecimento prévio: o grupo já estuda o Porto de Santos em Teoria do Aprendizado Estatístico, com dados de atracação da ANTAQ. Esses dados foram a

alternativa descartada: são tabelas numéricas (navios, horas, toneladas), não prosa que responda a perguntas.

3 Como o corpus foi obtido

O corpo de cada artigo foi salvo como texto em UTF-8, sem infobox, listas nem referências, em `estrutura/corpus/` (um `.txt` por página, enviados ao repositório em 19/08/2026). O script `estrutura/codigos/01a-ler-frases.R` quebra o texto em frases por `.`, `!` e `?` (e por `;` acima de 45 palavras), descarta fragmentos com menos de 3 palavras e numera as frases; o catálogo fica em `estrutura/corpus/frases-canonicas.csv`, com os mesmos IDs da Aula 01 ao julgamento da Aula 05.

O que deu errado. (i) O primeiro documento foi o artigo inteiro: só 3 documentos, e a busca não apontava o trecho. (ii) Cortes fixos de 7 a 10 palavras partiam frases ao meio, e os juízes não conseguiam julgar sem o contexto; a regra passou a ser a pontuação. (iii) Abreviações e decimais (`S.A.`, `Dr.`, `1,5`) quebravam frases no lugar errado e passaram a ser protegidas. (iv) Fragmentos de 1 ou 2 palavras foram descartados.

4 Defesa do corpus

A Tabela 1 reúne as verificações feitas sobre o corpus.

Tabela 1 – Diagnóstico do corpus (tokenização bruta da Aula 01)

Verificação	Resultado
Tamanho	122 documentos (frases) de 3 páginas
Tokens por documento	6 a 76 (média 28,6, mediana 25,5)
Vocabulário bruto	1.281 termos em 3.493 tokens (873 radicais após a Aula 03)
Por página	frases (parágrafos): <i>Porto de Santos</i> 88 (12); <i>Autoridade Portuária</i> 29 (5); <i>Paula Ribeiro</i> 5 (1)
Página que domina	<i>Porto de Santos</i> : 88 de 122 (72%)
Documentos suspeitos	0 com menos de 5 tokens; 1 com mais de 60 (d1.66)
Sujeira	119 com acento, 122 com pontuação, 59 com dígitos (de 122)

Fonte: Elaborada pelos autores (`entrega-1-corpus.R`).

Tamanho. São 122 documentos, acima da meta de 20 a 60. O excesso vem da unidade, não de páginas a mais: as mesmas três páginas dão 18 parágrafos, abaixo da faixa. O grupo mantém a frase, que já foi indexada e julgada nas Aulas 03 a 05.


Domínio de uma página. O porto responde por 72% do corpus, e o fundador por 5 frases. É a cara do tema — o artigo do porto é o mais longo e geral —, mas a pergunta 3 depende de poucas frases; a correção é acrescentar páginas, não cortar.

Documentos que não são prosa. Nenhuma frase tem menos de 5 tokens, porque a coleta descarta fragmentos. A única acima de 60, d1.66, foi lida e *não* é prosa: é a lista

de terminais do artigo, que perdeu as quebras de linha e virou uma frase só. Ela mostra o efeito do tamanho: é o 1.º lugar do TF-IDF na pergunta 2 só por ser longa, e o BM25, que normaliza pelo tamanho, a tira do top-5 (ROBERTSON; ZARAGOZA, 2009).

Sujeira. Quase todas as frases têm acento, todas têm pontuação grudada e 59 têm dígitos (anos, leis, toneladas): o esperado, tratado na Aula 03. Pela Figura 1, a maioria das frases tem entre 15 e 40 tokens.

Figura 1 – Tokens por documento



Fonte: Elaborada pelos autores.

Os termos mais frequentes são *de*, *a*, *e*, *o*, *da*, *do*, *porto*, *em*, *que*, *com*. Só 1 deles (*porto*) diz algo sobre o tema; os outros são artigos, preposições e conjunções — exatamente o que as *stopwords* da Aula 03 removem e o IDF da Aula 01 penaliza.

Veredito. A Tabela 2 roda as três perguntas no corpus com os métodos das aulas, avaliados pelo gabarito de graus 0/1/2 da Aula 05. As perguntas 1 e 3 são respondidas na 1.ª posição por todos os métodos ranqueados (d1.1 e d3.1, ambas de grau 2). Na pergunta 2 o nDCG é zero, mas o defeito está no gabarito, não no corpus: a frase d2.4, “Desde então, a APS administra a infraestrutura pública do Porto de...”, responde à pergunta e aparece em 3.º lugar no cosseno e no BM25, mas os dois juízes que a avaliaram deram grau 0, em 1 e 4 segundos. O AND não devolve nada nas três, porque nenhuma frase contém todos os termos; o OR devolve cerca de metade do corpus.

Tabela 2 – As três perguntas no corpus: documentos devolvidos e nDCG@5

Pergunta	AND	OR	1.º lugar	TF-IDF	Cosseno	BM25
1. Onde fica o porto	0	60	d1.1	0,64	0,72	0,74
2. Quem administra	0	69	d1.36	0,00	0,00	0,00
3. Quem foi o fundador	0	52	d3.1	0,76	0,76	0,76
Tempo médio (ms)	1,2	1,4		1,2	3,0	1,4

Fonte: Elaborada pelos autores. 1.º lugar do BM25; nDCG@5 com os graus 0/1/2 de 05-qrels.csv (JÄRVELIN; KEKÄLÄINEN, 2002); tempo médio de 200 execuções por consulta.

O corpus, portanto, contém a resposta às três perguntas. Ele é **provisório**: antes de congelar o gabarito, o grupo vai rejeitar a pergunta 2 (d2.2 e d2.4), quebrar a lista d1.66 em itens e acrescentar uma página sobre a Companhia Docas de Santos, para que a pergunta 3 não dependa de só 5 frases.

Referências

- JÄRVELIN, K.; KEKÄLÄINEN, J. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, v. 20, n. 4, p. 422–446, 2002.
- MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. Cambridge: Cambridge University Press, 2008.
- ROBERTSON, S.; ZARAGOZA, H. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, v. 3, n. 4, p. 333–389, 2009.
- WIKIPÉDIA. *Autoridade Portuária de Santos*. 2026. In: Wikipédia, a enciclopédia livre. Licença CC BY-SA. Disponível em: <https://pt.wikipedia.org/wiki/Autoridade_Portu%C3%A1ria_de_Santos>. Acesso em: 19 ago. 2026.
- WIKIPÉDIA. *Francisco de Paula Ribeiro*. 2026. In: Wikipédia, a enciclopédia livre. Licença CC BY-SA. Disponível em: <https://pt.wikipedia.org/wiki/Francisco_de_Paula_Ribeiro>. Acesso em: 19 ago. 2026.
- WIKIPÉDIA. *Porto de Santos*. 2026. In: Wikipédia, a enciclopédia livre. Licença CC BY-SA. Disponível em: <https://pt.wikipedia.org/wiki/Porto_de_Santos>. Acesso em: 19 ago. 2026.