

O corpus do projeto: *o Porto de Santos — o lugar, a autoridade pública e o fundador*

Equipe Shannon

Santos-SP, 2 de outubro de 2026

Fatec Baixada Santista, Rubens Lara | Tecnologia em Ciência de Dados
Projeto Integrador III — Motor de Busca | Prof. Dr. João Paulo Ferreira de Mello
Adriane da Costa Santos (RA 0051352511040) Danilo Prado de Lima Silva (RA 0051352521019)
Victória Cabral Quintério (RA 0051352521033)
Repositório: `projetointegrador3`

1 Introdução

O motor de busca do grupo é sobre o Porto de Santos, o mais movimentado da América Latina e eixo econômico da Baixada Santista. Quem o usaria é um estudante, jornalista ou analista que precisa achar *a frase* que responde a uma dúvida sobre o porto. O que se atende é a *necessidade de informação*, não a consulta literal (MANNING; RAGHAVAN; SCHÜTZE, 2008, cap. 1); por isso as perguntas vieram antes do corpus: **(1)** onde fica o porto; **(2)** quem o administra hoje; **(3)** quem foi Francisco de Paula Ribeiro e qual a sua ligação com o porto. Este texto apresenta a fonte, a coleta e a evidência de que o corpus responde às três.

2 A fonte e o documento

O texto vem da Wikipédia em português, sob licença CC BY-SA, de três páginas: *Porto de Santos* (WIKIPÉDIA, 2026c), *Autoridade Portuária de Santos* (WIKIPÉDIA, 2026a) e *Francisco de Paula Ribeiro* (WIKIPÉDIA, 2026b), salvas em agosto de 2026: o **lugar**, a **autoridade pública** e o **fundador**, uma para cada pergunta. São $N = 122$ documentos.

Um documento é **uma frase pontuada**, $dN.k$ (página N , frase k): a menor unidade que responde sozinha a uma pergunta. O artigo inteiro diria só “está no artigo do porto”, e o parágrafo — padrão do curso — daria 18 documentos, abaixo da faixa e misturando assuntos. A frase $d1.1$, “Porto de Santos é um porto estuarino, localizado nos municípios de Santos, Guarujá e...”, responde sozinha à pergunta 1.

A motivação foi o conhecimento prévio: o grupo já estuda o porto em Teoria do Aprendizado Estatístico, com dados da ANTAQ — a alternativa descartada, por serem tabelas numéricas, não prosa.

3 Como o corpus foi obtido

O corpo de cada artigo, sem infobox nem referências, foi salvo em UTF-8 em `estrutura/corpus/` (19/08/2026). O script `01a-ler-frases.R` quebra o texto por `.`, `!` e `?` (e `;` acima de 45 palavras), descarta fragmentos de menos de 3 palavras e numera as frases em `frases-canonicas.csv`, com os mesmos IDs da Aula 01 à 05.

O que deu errado. (i) O artigo inteiro como documento dava só 3 documentos. (ii) Cortes fixos de 7 a 10 palavras partiam frases, e os juízes não julgavam sem contexto; passou-se à pontuação. (iii) Abreviações e decimais (**S.A.**, 1,5) quebravam frases e passaram a ser protegidas. (iv) Fragmentos de 1 ou 2 palavras foram descartados.

4 Defesa do corpus

Tabela 1 – Diagnóstico do corpus (tokenização bruta da Aula 01)

Verificação	Resultado
Tamanho	122 documentos (frases) de 3 páginas
Tokens por documento	6 a 76 (média 28,6, mediana 25,5)
Vocabulário bruto	1.281 termos em 3.493 tokens (873 radicais após a Aula 03)
Por página	frases (parágrafos): <i>Porto de Santos</i> 88 (12); <i>Autoridade Portuária</i> 29 (5); <i>Paula Ribeiro</i> 5 (1)
Página que domina	<i>Porto de Santos</i> : 88 de 122 (72%)
Documentos suspeitos	0 com menos de 5 tokens; 1 com mais de 60 (d1.66)
Sujeira	119 com acento, 122 com pontuação, 59 com dígitos (de 122)


Fonte: Elaborada pelos autores (`entrega-1-corpus.R`).

Tamanho. São 122 documentos (Tabela 1), acima da meta de 20 a 60, por causa da unidade: em parágrafos seriam 18. A frase fica, pois já foi indexada e julgada. **Domínio.** O porto tem 72% do corpus e o fundador só 5 frases: é a cara do tema, mas a pergunta 3 depende de poucas frases; a correção é acrescentar páginas. **Não prosa.** A única frase acima de 60 tokens, d1.66, é uma lista de terminais que perdeu as quebras de linha; por ser longa, é o 1.º lugar do TF-IDF na pergunta 2, e o BM25, que normaliza pelo tamanho, a tira do top-5 (ROBERTSON; ZARAGOZA, 2009). **Sujeira.** Acentos, pontuação grudada e 59 frases com dígitos: o esperado, tratado na Aula 03. Pela Figura 1, a maioria das frases tem de 15 a 40 tokens.

Os termos mais frequentes são *de*, *a*, *e*, *o*, *da*, *do*, *porto*, *em*, *que*, *com*: só porto fala do tema; o resto é o que as *stopwords* removem.

Veredito. Na Tabela 2, as perguntas 1 e 3 têm a resposta (d1.1, d3.1, grau 2) em 1.º lugar em todos os métodos ranqueados. Na pergunta 2 o nDCG é zero por defeito do gabarito, não do corpus: d2.4, “Desde então, a APS administra a infraestrutura pública

Figura 1 – Tokens por documento



Fonte: Elaborada pelos autores.

do Porto de...”, responde e fica em 3.º no cosseno e no BM25, mas recebeu grau 0 dos dois juízes, em 1 e 4 segundos. O AND não devolve nada; o OR devolve metade do corpus.

Tabela 2 – As três perguntas no corpus: documentos devolvidos e nDCG@5

Pergunta	AND	OR	1.º lugar	TF-IDF	Cosseno	BM25
1. Onde fica o porto	0	60	d1.1	0,64	0,72	0,74
2. Quem administra	0	69	d1.36	0,00	0,00	0,00
3. Quem foi o fundador	0	52	d3.1	0,76	0,76	0,76
Tempo médio (ms)	1,2	1,4		1,2	3,0	1,4

Fonte: Elaborada pelos autores. 1.º lugar do BM25; nDCG@5 com os graus 0/1/2 de 05-qrels.csv (JÄRVELIN; KEKÄLÄINEN, 2002); tempo médio de 200 execuções por consulta.

O corpus contém a resposta às três perguntas e é **provisório**: antes de congelar o gabarito, o grupo vai rejulgar a pergunta 2, quebrar d1.66 em itens e acrescentar uma página sobre a Companhia Docas de Santos.

Referências

- JÄRVELIN, K.; KEKÄLÄINEN, J. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, v. 20, n. 4, p. 422–446, 2002.
- MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. Cambridge: Cambridge University Press, 2008.
- ROBERTSON, S.; ZARAGOZA, H. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, v. 3, n. 4, p. 333–389, 2009.
- WIKIPÉDIA. *Autoridade Portuária de Santos*. 2026. In: Wikipédia, a enciclopédia livre. Licença CC BY-SA. Disponível em: <https://pt.wikipedia.org/wiki/Autoridade_Portu%C3%A1ria_de_Santos>. Acesso em: 19 ago. 2026.
- WIKIPÉDIA. *Francisco de Paula Ribeiro*. 2026. In: Wikipédia, a enciclopédia livre. Licença CC BY-SA. Disponível em: <https://pt.wikipedia.org/wiki/Francisco_de_Paula_Ribeiro>. Acesso em: 19 ago. 2026.
- WIKIPÉDIA. *Porto de Santos*. 2026. In: Wikipédia, a enciclopédia livre. Licença CC BY-SA. Disponível em: <https://pt.wikipedia.org/wiki/Porto_de_Santos>. Acesso em: 19 ago. 2026.