
Entrega de meio de semestre

A ficha, o repositório que roda, e cinco minutos ao vivo

Projeto Integrador III ■ Ciência de Dados

FATEC — Tecnologia em Ciência de Dados

O que o grupo entrega no fim do semestre

Um **motor de busca** sobre um tema escolhido pelo grupo, **identificado com a Baixada Santista**, construído sobre um corpus que o próprio grupo coletou.

- Ele não se faz no fim: **cresce a cada aula**, na parte prática (Parte D), em grupo.
- A memória do projeto é a **ficha** — `consolidados/00_FICHA_PROJETO.md` — criada na Aula 01 e atualizada em toda sessão prática.
- A entrega de meio de semestre é uma **foto** desse processo. Não é um trabalho à parte.

Três coisas, uma data

1. A ficha

O projeto tem nome, tema, fonte e corpus — **decididos** e registrados.

2. O repositório

Eu clono e **roda**. Sem “na minha máquina funciona”.

3. Cinco minutos

O motor responde às três consultas de trabalho, **ao vivo**, e alguém explica.

Data

7 de outubro. Repositório marcado com a *tag* entrega-1 até as 23h59 do dia anterior; demonstrações na aula.

1. A ficha do projeto

É o arquivo consolidados/00_FICHA_PROJETO.md, no formato do FICHA_PROJETO_modelo.md. O que eu leio nela:

seção	o que precisa estar decidido
Identidade	grupo, integrantes, endereço do repositório
Tema	uma frase; a ligação com a Baixada; quem usaria ; três perguntas que o motor responde
Fonte	de onde; licença ; os títulos das páginas; o que é <i>um</i> documento — e por quê
A cara do corpus	quantos documentos (20 a 60); tamanhos; vocabulário; as três consultas de trabalho
Decisões e linha do tempo	uma entrada por sessão prática feita até aqui

Campo em branco (--) é honesto e aceito. Campo preenchido com palpite da LLM, não.

O que faz uma ficha ser boa

Passa

- “As praias de Guarujá e o turismo” — usuário: quem planeja um fim de semana.
- Fonte: Wikipédia pt, CC BY-SA, 4 artigos, 37 parágrafos.
- Um documento = um parágrafo, “porque é a menor unidade que responde sozinha”.

Não passa

- “A Baixada Santista” — sobre o quê? para quem?
- Fonte: “sites de notícias” — sem licença, sem lista.
- Um documento = o artigo inteiro — a busca devolve “está em Santos”; em qual dos 300 parágrafos?

As três perguntas da seção 2 têm que ser coisa que **alguém digitaria num buscador**.

2. O repositório que roda

A estrutura (Aula 01)

```
projeto-<grupo>/  
  estrutura/banco-de-dados/  
    coletar.R  docs.rds  origem.rds  
  estrutura/codigo/  
    aula01.R  aula02.R  (aula03.R...)  
  consolidados/  
    00_FICHA_PROJETO.md  
    aulaNN_consolidado.md  
(individuais)  
  aulaNN_parteD_consolidado.md  
(grupo)  
  README.md
```

O teste que eu faço

- ① git clone + git checkout entrega-1
- ② rodo coletar.R — o corpus se refaz?
- ③ rodo aula02.R — as três consultas de trabalho dão os rankings que estão na ficha?

Se um passo falha, a entrega volta com o erro anotado. Uma segunda chance, em 7 dias.

O que o histórico do repositório conta

- **Commits ao longo do tempo**, não um só na véspera. O projeto cresce a cada aula — o histórico tem que mostrar isso.
- **Mais de um autor**. É projeto de grupo; se só um nome aparece, eu pergunto por quê na demonstração.
- **Os consolidados de grupo** das Partes D feitas: eles dizem quem estava presente e quem digitou.
- `to_delete/ vazia`. Rascunho não entra na *tag*.

Um lembrete sobre a LLM

Código escrito com a tutora é o esperado — é assim que o curso funciona. Código que ninguém do grupo sabe explicar é o problema. A demonstração existe para isso.

3. Cinco minutos ao vivo

O roteiro — cronometrado

- ① **1 min** — o tema e quem usaria, lendo a ficha.
- ② **2 min** — as três consultas de trabalho rodando no R, no corpus do grupo. Os cinco primeiros de cada.
- ③ **2 min** — **um membro sorteado** explica um ranking: que termo puxou o primeiro lugar, e onde isso aparece nos números.

O que eu observo

- O motor roda do repositório, não de um arquivo solto.
- A explicação cita **termo e número** (qw, w[, melhor]), não “é o mais importante”.
- Qualquer membro consegue — por isso o sorteio.

Sem slides. Terminal e a ficha aberta bastam.

item	critério	peso
Ficha	tema com usuário e ligação com a Baixada; fonte com licença; critério de documento justificado; corpus 20–60; decisões registradas	40%
Repositório	clona e roda (<code>coletar.R</code> , <code>aula02.R</code>); estrutura da Aula 01; histórico com mais de um autor e mais de um dia	30%
Demonstração	rankings ao vivo; explicação com números pelo membro sorteado; 5 minutos	30%

- A nota é **do grupo**. O sorteio na demonstração é o que a torna de todos.
- Ficha e repositório são corrigidos **antes** da aula; a demonstração é na aula.

- **Relatório.** A ficha é o relatório desta entrega. Texto a mais não vale ponto.
- **Slides.** A demonstração é no terminal.
- **BM25, índice, gabarito.** Só o que as Partes D das Aulas 01 e 02 produziram. Quem já avançou, ótimo — entra na ficha como estado, não vale extra.
- **Corpus grande.** 20 a 60 parágrafos. Ele cresce na Aula 05, não agora.
- **Acentos e pontuação resolvidos.** Corpus sujo é o esperado nesta altura; a limpeza é a Aula 03.

Os próximos 15 dias

quando	o quê
esta semana	grupo formado; repositório criado com a estrutura; Parte D da Aula 01 feita em grupo, com o FICHA_PROJETO_modelo.md → a ficha nasce
semana que vem	Parte D da Aula 02 → as três consultas de trabalho, os rankings, a ficha atualizada
até 6/10, 23h59	tag entrega-1; conferir que git clone + rodar funci- ona em outra máquina
7/10, em aula	demonstrações, 5 minutos por grupo, ordem sorteada

Se travar

A ficha tem um campo “pendente”. Use. Entrega com pendência declarada vale mais que entrega com buraco escondido.

Perguntas que sempre aparecem

Podemos trocar de tema depois? Podem. Vira uma decisão registrada na seção 6 da ficha, com o motivo; a antiga fica na história.

E se um membro não participou? A ficha e os consolidados de grupo dizem quem estava presente. Eu leio.

A LLM pode escrever a ficha? Ela **preenche** com o que o grupo decidiu — é assim que o guia funciona. Decidir é de vocês.

Precisa ser Wikipédia? Não. Precisa ter licença clara e texto suficiente. O PLANO_DADOS_REGIONAL.md lista outras fontes.

Vale nota individual? Não nesta entrega. Os consolidados individuais da teoria contam como acompanhamento.